

Actividad 5

Entrenamiento y Ajuste de Modelos

Alumno:	Alejandro Islas Lopez
Materia:	Inteligencia Artificial Aplicada
Fecha:	Junio 2025
Dataset:	Resenas de Restaurante - Zapopan, Jalisco
Tarea:	Clasificacion de Sentimientos (POS / NEU / NEG)
Modelos:	Regresion Logistica vs Random Forest
Tracking:	MLflow - Experimento: Actividad5_Sentimientos

1. Descripcion del Dataset

El dataset utilizado es un conjunto sintetico de 400 resenas de un restaurante de cocina tradicional mexicana en Zapopan, Jalisco. Fue generado con semilla fija (seed=42) para garantizar reproducibilidad. Cubre opiniones de tres canales: Google Reviews, Facebook y Encuestas Internas.

Diccionario de datos

Campo	Tipo	Valores	Descripcion
id	Entero	1 - 400	Identificador unico
comentario	Texto	Variable	Opinion del cliente
sentimiento	Categorico	POS / NEU / NEG	Etiqueta de sentimiento
fecha	Fecha	2024-01-01 a 2024-12-31	Fecha de publicacion
fuelle	Categorico	Google / Facebook / Encuesta	Canal de origen

Distribucion de clases

Sentimiento	Cantidad	Porcentaje
POS (Positivo)	158	39.5%
NEU (Neutral)	132	33.0%
NEG (Negativo)	110	27.5%

Supuestos

- 1. El dataset es sintetico; los patrones son mas regulares que datos reales.
- 2. Los tres canales tienen distribuciones de sentimiento similares.
- 3. El vocabulario representa el español mexicano coloquial de Zapopan, Jalisco.
- 4. Las etiquetas son correctas sin necesidad de revision adicional.

[imagen no disponible: eda_distribucion.png]

[imagen no disponible: eda_wordclouds.png]

2. Proceso de Limpieza y Estandarizacion

Pipeline implementado en fuentes/datos_prep.py. No se encontraron valores nulos en el dataset.

Paso	Transformacion	Justificacion
1	Verificacion de nulos	Eliminar registros incompletos
2	Conversion a minusculas	Normalizar vocabulario
3	Eliminacion de caracteres esp.	Conservar letras, acentos, espacios
4	Normalizacion de espacios	Eliminar espacios multiples
5	Encoding de etiquetas	NEG=0, NEU=1, POS=2
6	Vectorizacion TF-IDF	Unigramas+bigramas, 5000 features
7	Split estratificado 80/20	Preservar distribucion de clases

El vectorizador TF-IDF con sublinear_tf=True reduce el peso de palabras muy frecuentes. El rango de n-gramas (1,2) captura patrones como 'muy bueno' o 'tiempo de espera' que son mas informativos que palabras individuales.

3. Estrategia de Versionamiento

Repositorio en GitHub: <https://github.com/aislaslo/DesignThinking>

Versionamiento semantico documentado en CHANGELOG.md.

Commit	Tipo	Descripcion
7fb0106	feat	Estructura inicial: datos, fuentes, README, CHANGELOG
f59cfa0	fix	Eliminar parametro deprecated multi_class

Convencion: feat (nueva funcionalidad), fix (correccion), docs (documentacion). Cada cambio al dataset o hiperparametros se documenta en CHANGELOG.md.

4. Descripcion de los Modelos Entrenados

Modelo 1 - Regresion Logistica

Clasificador lineal que modela la probabilidad de pertenencia a cada clase mediante funcion softmax en el caso multiclase. Es interpretable, eficiente y sirve como linea base robusta para clasificacion de texto con TF-IDF, donde la relacion entre features y etiquetas tiende a ser aproximadamente lineal.

Modelo 2 - Random Forest

Ensemble de arboles de decision entrenados con bootstrap sampling y seleccion aleatoria de features. Robusto al ruido, captura interacciones no lineales entre terminos y maneja bien la alta dimensionalidad del espacio TF-IDF.

5. Configuracion de Hiperparametros

GridSearchCV con validacion cruzada estratificada 5-fold, scoring=f1_macro.

Regresion Logistica

Hiperparametro	Valores evaluados	Optimo
C (regularizacion)	0.01, 0.1, 1, 10	10
solver	lbfgs, saga	lbfgs
max_iter	1000 (fijo)	1000

Random Forest

Hiperparametro	Valores evaluados	Optimo
n_estimators	100, 200	100
max_depth	None, 10, 20	None
min_samples_split	2, 5	5

6. Metricas Obtenidas

Metrica	Regresion Logistica	Random Forest
Accuracy	1.0000	0.9500
Precision (macro)	1.0000	0.9630

Recall (macro)	1.0000	0.9464
F1-Score (macro)	1.0000	0.9522
ROC-AUC (OVR)	1.0000	0.9995
CV F1 mean	1.0000	0.9783
CV F1 std	0.0000	0.0232

La Regresion Logistica alcanzo metricas perfectas (1.0). Esto es caracteristico de datasets sinteticos donde los patrones son altamente regulares y separables linealmente. En produccion con datos reales se esperan valores mas representativos.

[imagen no disponible: comparativa_modelos.png]

7. Comparacion Estadistica de Resultados

Criterio	Regresion Logistica	Random Forest	Ventaja
Accuracy	1.000	0.950	Logistica (+5.0%)
F1-macro	1.000	0.952	Logistica (+4.8%)
ROC-AUC	1.000	0.999	Logistica (~igual)
Tiempo entrenamiento	< 1s	~15s	Logistica
Interpretabilidad	Alta	Media	Logistica
No linealidad	No	Si	Random Forest

Para datos reales, Random Forest podria reducir la brecha gracias a su capacidad de capturar interacciones no lineales entre terminos.




Figura 4. Matriz de confusion - Regresion Logistica.




Figura 5. Matriz de confusion - Random Forest.




Figura 6. Curvas ROC (OVR) - Regresion Logistica.




Figura 7. Curvas ROC (OVR) - Random Forest.

8. Evidencia del Uso de MLflow

MLflow configurado en modo local (backend-store-uri: mlruns/). Experimento 'Actividad5_Sentimientos' con dos runs registrados.

Tipo	Que se registro
Parametros	C, solver, n_estimators, max_depth, min_samples_split, cv_folds, ngram_range, max_features
Metricas	accuracy, precision_macro, recall_macro, f1_macro, roc_auc_ovr, cv_f1_macro_mean, cv_f1_macro_std
Artefactos	Matriz de confusion (PNG), Curvas ROC (PNG), modelo serializado (sklearn format)

Panel disponible en: <http://127.0.0.1:5000>
Comando: mlflow ui --backend-store-uri file:///ruta/mlruns --port 5000

9. Reflexion sobre Deuda Tecnica y MLOps

Deuda tecnica identificada

Deuda	Descripcion	Prioridad
Dataset sintetico	Patrones regulares; puede no generalizar a datos reales	Alta
Fuga de datos	Vectorizador ajustado antes del split; debe ir en Pipeline	Alta
Sin Pipeline sklearn	Preprocesamiento y modelo separados dificultan despliegue	Alta
Sin stopwords	No se filtran palabras vacias en espanol	Media
Sin drift monitoring	No se detecta cambio en vocabulario de clientes	Media

Mejoras MLOps propuestas

Mejora	Impacto
sklearn.Pipeline para preprocesamiento + modelo	Elimina fuga de datos y simplifica despliegue
MLflow Model Registry con staging dev->prod	Versionamiento formal y promocion controlada
Dataset real de resenas etiquetadas manualmente	Mejora la generalizacion en produccion
CI/CD con GitHub Actions para reentrenamiento	Automatiza el ciclo de mejora del modelo
Endpoint serverless (Cloud Run / AWS Lambda)	Integracion con sistema POS del restaurante